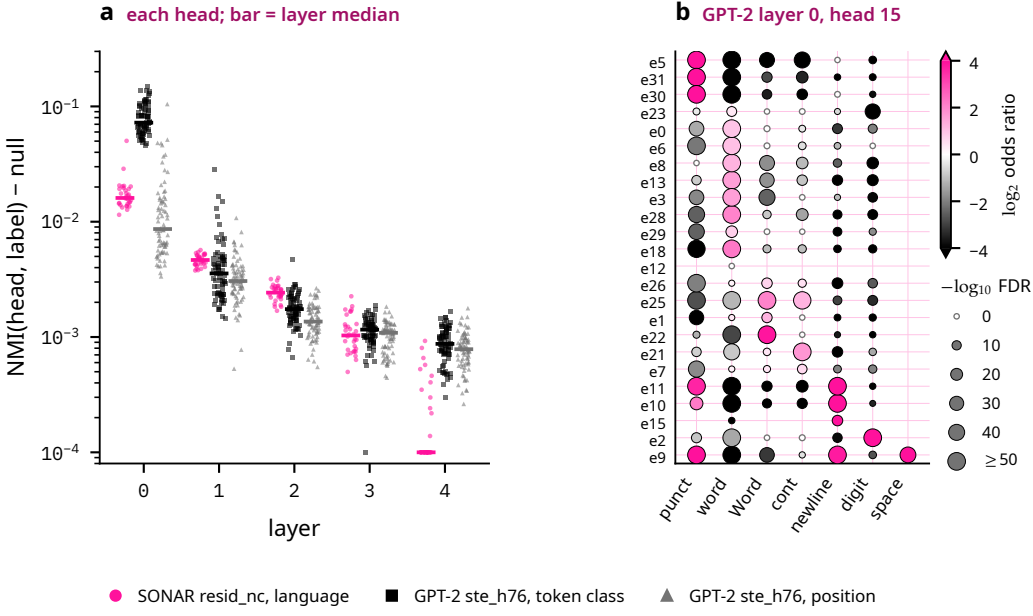

a each head; bar = layer median
NMI(head, label) − null
10^{-1}
10^{-2}
10^{-3}
10^{-4}
0
1
2
3
4
layer
b GPT-2 layer 0, head 15
e5
e31
e30
e23
e0
e6
e8
e13
e3
e28
e29
e18
e12
e26
e25
e1
e22
e21
e7
e11
e10
e15
e2
e9
punct
word
Word
cont
newline
digit
space
4
2
0
−2
−4
$\log_2$ odds ratio
$-\log_{10}$ FDR
0
10
20
30
40
≥ 50
SONAR resid_nc, language
GPT-2 ste_h76, token class
GPT-2 ste_h76, position